FACULTÉ DES SCIENCES DE TUNIS
ANNÉE UNIVERSITAIRE 2026-2027
ENSEIGNANTE : Dr. ASMA MEKKI
FILIÈRE : IDS 5

MLOps
TP-FR 1 : Collecte et exploration

PROJET FIL ROUGE : ***Cyberbullying Detection sur données multimodales (texte + image)***

TP1 : Collecte et exploration des données (Scraping + Préparation initiale)

Objectif

Apprendre à :

- identifier et extraire des données multimodales pertinentes depuis le web (texte + images),
- structurer et stocker les données,
- nettoyer et documenter la collecte pour assurer traçabilité et reproductibilité.

Contexte

Le cyberharcèlement (*cyberbullying*) se manifeste sous plusieurs formes sur les réseaux sociaux : messages insultants, moqueries, propos haineux, parfois accompagnés d'images ou de mèmes dégradants. Dans ce TP, vous allez **collecter un jeu de données multimodal** (texte et images) depuis plusieurs sources publiques afin de préparer un corpus pour l'analyse ultérieure.

Partie 1 — Définir le périmètre de collecte

1. **Choisissez un thème global :** le *cyberharcèlement en ligne*.
   Vous allez constituer un corpus de messages susceptibles d'appartenir à plusieurs catégories, par exemple :
   - **Insulte / moquerie personnelle** (e.g., "You're so ugly")
   - **Menace / intimidation** (e.g., "You should kill yourself")
   - **Haine ciblée / discrimination** (e.g., "All [group] are worthless")
   - **Provocation légère / ironie**
   - **Messages neutres / non toxiques**
2. **Choisissez au moins deux sources différentes** parmi :
   - **Réseaux sociaux** : Twitter/X, Reddit, YouTube comments, Instagram (uniquement via contenu public).
   - **Forums ou discussions publiques** : e.g., 4chan, StackExchange, jeux en ligne, etc.

3. **Avant de commencer :**
    - Vérifiez la légalité et le respect du *robots.txt* des sites.
    - Ne collectez **aucune donnée personnelle** identifiable (noms, emails, images de visages non floutées).
    - Définissez vos **mots-clés de recherche** selon les classes que vous souhaitez détecter.

    Exemples de mots-clés (anglais) :

    ```
    bully, harassment, hate, kill, loser, ugly, stupid, idiot, threat, toxic,
    disgusting
    ```

Partie 2 — Extraction des données

1. **Utilisez des outils libres** pour extraire les contenus comme :
    - `snscrape` (Twitter/X)
    - `praw` ou API Pushshift (Reddit)
    - `BeautifulSoup` ou `Selenium` pour forums ou YouTube comments.
2. **Pour chaque élément extrait, collectez:**
    - `date`
    - `texte brut`
    - `lien source`
    - `identifiant (anonymisé)`
    - `métadonnées` (nb likes, votes, etc.)
    - `lien image` ou image téléchargée (si disponible)
3. **Stockez les données sous forme tabulaire** (CSV, JSON ou SQLite).
   Chaque ligne doit correspondre à une entrée unique :
   `id | date | text | media | url | source | metadata`
4. **Volume attendu :**
    - Minimum : 100 entrées (texte).
    - Minimum : 20 images (mèmes, captures, etc.).

Partie 3 — Nettoyage et structuration

1. Supprimez les doublons, posts vides ou non pertinents.
2. Nettoyez le texte :
    - enlever URLs, mentions `@`, hashtags `#`, emojis si non utiles.
    - mettre en minuscules, normaliser les caractères.
3. Conservez uniquement les colonnes pertinentes : `date, clean_text, media, url, source`
4. Sauvegardez un fichier `cyberbullying_raw_clean.csv`.

Partie 4 — Vérification et analyse rapide

1. **Analyse statistique minimale :**
    - Nombre total de messages.
    - Répartition par source.
    - Taux de messages avec image.
    - Longueur moyenne des textes.

2. **Analyse qualitative rapide :**
    - Montrez 10 exemples variés.
    - Évaluez la diversité lexicale.
    - Vérifiez la pertinence du vocabulaire par rapport au thème.
3. **Préparez un mini-rapport (10 lignes max)** décrivant :
    - Vos sources principales.
    - Vos mots-clés.
    - La taille finale du corpus.
    - Les premiers constats (qualité, diversité, bruit).

Partie 5 — Organisation du projet

Créez un répertoire structuré :

```
TP1_Collecte/
│
├── data/
│   ├── cyberbullying_raw.csv
│   ├── cyberbullying_raw_clean.csv
│   └── images/
│
├── notebooks/
│   └── TP1_collecte.ipynb
│
└── README.md   ← description des sources et choix
```

Partie 6 — Suivi et traçabilité (introduction MLOps)

Pour introduire la notion de traçabilité du cycle de vie des données à l'aide d'un outil d'orchestration ou de suivi d'expériences.
Utilisez **MLflow** ou un équivalent open source (par ex. **DVC**) afin de :

- documenter les paramètres de collecte (sources, mots-clés, date de scraping, nombre d'éléments extraits),
- enregistrer les versions des jeux de données produits (`cyberbullying_raw.csv`, `cyberbullying_raw_clean.csv`),
- sauvegarder les fichiers importants et le mini-rapport dans un run MLflow pour assurer la reproductibilité du processus.

Exemple

```python
import mlflow

mlflow.set_experiment("Cyberbullying_Data_Collection")

with mlflow.start_run():
    mlflow.log_param("sources", ["Twitter", "Reddit"])
    mlflow.log_param("keywords", ["bully", "hate", "ugly"])
    mlflow.log_param("nb_texts", 120)
    mlflow.log_param("nb_images", 25)
    mlflow.log_artifact("data/cyberbullying_raw_clean.csv")
    mlflow.log_artifact("README.md")
```